

Project work NLP

Sturm und Drang e Klassizismus: risultati e analisi del notebook

Corpus: 38 opere teatrali (21 SD, 130.579 parole, 17 Klassizismus, 134.245 parole), lemmatizzati con spaCy (de_core_news_sm, confronto con de_core_news_lg).

Dai 42 file XML si arriva a 40 opere dopo la fusione delle tre parti del *Wallenstein* e a 38 dopo l'esclusione dei due frammenti di Leisewitz (meno di 1.000 parole).

1. Sintesi

Il lessico dei due gruppi di drammi differisce abbastanza chiaramente e la differenza regge ai controlli per opera, per autore e per sottocampione, nonostante un difetto nella gestione delle stopwords.

Il notebook:

1. regge la differenza tra il lessico del corpo, della vita quotidiana e dei ruoli sociali (SD) e quello di potere, stato, legge e valori (*Klassizismus*), e le parole non verbali più forti.
2. verbi: nello SD azioni concrete e corporee di registro colloquiale (*lachen, kriegen, schlafen, laufen, trinken*), nel *Klassizismus* azioni di registro alto su silenzio, protezione e decoro (*schweigen, nahen, ziemen, beschützen, retten, ehren*). Valgono solo i verbi non toccati dal difetto delle stopwords, *schweigen* e *nahen* con riserva (sezione 7).
3. i verbi modali: *wollen, müssen, können, sollen* sono più frequenti nello SD (*wollen* con l'effetto più netto), solo *dürfen* va verso la *Klassizismus*, con un effetto per opera più debole ($r = -0,44$), ma non piccolo in log₂ ratio ($-0,66$).

Se si dividono i 38 drammi in due gruppi a caso, il programma trova in media 42 parole tipiche di un gruppo, e al massimo 116. Con la divisione vera ne trova 369.

Le parole tipiche.

Sturm und Drang: corpo, vita quotidiana e ruoli sociali:

Kopf (testa), *Teufel* (diavolo), *Kerl* (tizio), *Hund* (cane), *Mädchen* (ragazza), *Herr* (signore), spesso nella formula *gnädiger Herr* («signor mio»).

È un tedesco concreto e colloquiale.

Classicismo: potere, stato, legge e valori.

Volk (popolo), *Heer* (esercito), *Pflicht* (dovere), *Gesetz* (legge), *edel* (nobile), *kühn* (audace).

È un registro elevato.

I verbi.

SD: azioni fisiche e quotidiane,

come *lachen* (ridere), *schlafen* (dormire), *laufen* (correre), *trinken* (bere) e *kriegen* (prendere, in tono colloquiale).

Classicismo: azioni solenni,

come *schweigen* (tacere), *beschützen* (proteggere), *retten* (salvare), *ehren* (onorare) e *ziemen* (addirsi).

I verbi di volontà e dovere. *Wollen* (volere) è molto più frequente nello SD: circa 78 volte ogni 10.000 parole contro 44. Seguono *müssen* (dovere), *können* (potere) e *sollen*. Solo *dürfen* (essere permesso) va, in modo lieve, verso il Classicismo. Questo conferma in parte la tesi secondo cui i personaggi dello SD sono spinti da impulsi e volontà.

2. Quali parole reggono

Su 100 parole controllate (50 per classe), 60 sono A (robuste), 18 sono B (solide ma sensibili) e 22 sono C (fragili). Per essere A una parola deve superare tutti i controlli della tabella, ogni riga indica quante delle 50 parole di ciascuna classe la superano.

Controllo	SD (su 50)	Klassizismus (su 50)
G ² sopra la soglia di Bonferroni (23,1)	50	50
Regge il confronto per opera (Mann-Whitney)	42	43
Concorda a pesi uguali per opera	50	50
Stessa direzione dentro Goethe e Schiller	47	44
Regge con i log-odds (secondo misura)	40	48
Stabile togliendo un autore alla volta	40	40
Stabile senza gli autori minori della Klassizismus	49	45
Stabile con al massimo 3 opere per autore	46	46
Stabile senza le opere sotto 2.000 parole	50	50
Stabile in 18 combinazioni di parametri	43	48
Presente anche con il modello spaCy grande	49	50
A (tutti i controlli)	28	32

- SD, robuste (28): *herr, kopf, teufel, junge, sehen, kerl, sagen, mädchen, leute, gesicht, hund, lachen, kriegem, gnädig, narr, herum, schlafen, empfindung, hübsch, jung, freilich, geben, laufen, unglücklich, hals, lesen, trinken, wetter.*
- Dentro Goethe e Schiller vanno nella stessa direzione: *kopf* +2,7 e +2,6, *teufel* +2,3 e +2,3, *junge* +3,8 e +4,1 (log₂ ratio).
- Klassizismus, robuste (32): *volk, schnell, stets, hoch, haupt, nahen, heer, frei, fürstin, fremd, königlich, edel, brust, geschick, vertrauen, schweigen, gunst, kühn, furcht, senden, folgen, streng, pflicht, froh, teuer, rettung, gesetz, rasch, neu, ziemen, zart, bund.*

- Fragili SD (11): *papa, mama, hofmeister, gräfin, hauptmann* compaiono in poche opere (da 4 a 6 opere SD) e non reggono il confronto per opera. *Frau, liebe, bruder* sono invece diffuse (17-20 opere SD) ma frequenti anche nella Klassizismus, e per questo non reggono per opera. *Wissen, brav, gewiß* si invertono in almeno un autore.
- Fragili Klassizismus (11): *könig, königin, kaiser, götter, glück, land, jungfrau, sieg, vaterland, reich, feind*. Sette non reggono il confronto per opera (*könig, königin, kaiser, götter, glück, land, jungfrau*) e sei si invertono in un autore (*kaiser, feind, reich, vaterland, land, sieg*), togliendo Schiller cadono *königin, kaiser, feind, reich, land, jungfrau*.

Parole come *mädel, nase, maul, familie, komödie* sono B: hanno poche occorrenze (39-66 nello SD, quasi nessuna nella Klassizismus). *Schreiben, küssen, bekommen* sono B perché dipendono da Lenz o Klinger.

Nel Klassizismus le 7 parole B sono *eigen* e *treu* (cadono senza Schiller), *gemüt* (cade senza Goethe), *unglücklich* (cade senza Schiller e con al massimo 3 opere per autore) ed *einst* (cade senza gli autori minori).

3. Campi semantici

Le 300 parole con il G² più alto tra le 369 distintive (295 hanno un vettore nel modello grande) sono state raggruppate in 8 campi con i vettori del modello grande.

Campo	Contenuto	Verso
1	Corpo e vita quotidiana: <i>kopf, gesicht, hals, nase, schlafen, trinken, wein, küssen, papa, mama</i>	SD (33 parole SD su 36)
4	Persone e ruoli sociali: <i>herr, junge, frau, mädchen, familie, hofmeister, hauptmann, gräfin</i>	SD (24 su 31)
5	Parlare, pregare, affetto: <i>sagen, wissen, bitten, beten, verzeihen, verlieben</i> (con residui come <i>sag, hol</i>)	SD (19 su 27)

Campo	Contenuto	Verso
0	Stato, legge, dovere: <i>pflicht, gesetz, frei, bund, bürger, rettung, vertrauen</i>	Klassizismus (40 su 49)
2	Potere e guerra: <i>könig, volk, heer, feldherr, kaiser, sieg, thron, schlacht</i>	Klassizismus (25 su 28)
7	Giudizi ed emozioni: SD <i>teufel, narr, garstig, verflucht</i> , Klassizismus <i>edel, kühn, mächtig, unheil, schrecken</i>	Misto, più Klassizismus (35 su 53, q = 0,013)
6	Verbi d'azione: SD <i>sehen, kriegen, laufen, lesen, machen, stecken</i> , Klassizismus <i>senden, folgen, sprechen, erscheinen, vollbringen</i>	Misto (19 SD, 23 Klassizismus), non significativo (q = 0,16)
3	Campo eterogeneo: Klassizismus <i>schnell, glück, rasch, geschick, teuer</i> , SD <i>herum, hübsch, wetter, spaß, geld</i>	Nessuno (q = 0,30)

Il campo 6 raccoglie quasi solo verbi e contiene il contrasto di registro dentro lo stesso campo: *kriegen, laufen, bekommen, stecken* (concreto, SD) contro *vollbringen, erscheinen, verbergen* (astratto, Klassizismus).

Un contrasto analogo c'è nel campo 7: *teufel, narr, garstig, verflucht* contro *edel, kühn, mächtig, schrecken*. Nelle liste estese (oltre le prime 50) compaiono per lo SD anche *geld, dukat, taler* (denaro), *wein, essen, fressen* (cibo e bevande) e *genie*, per il Klassizismus *freiheit, schicksal, ruhm, opfer, heilig*.

4. Case study: Herr

Nello SD *Herr* è soprattutto appellativo e titolo: *gnädiger Herr* (87 volte), *Herr von* (56), *Herr Major, Vetter, Assessor, Baron, Magister*. Nel Klassizismus prevalgono usi come *o Herr* (21) e *Herr der...* (23), anche se *gnädger Herr* compare pure lì (12).

Le parole vicine entro tre posizioni (sezione 11c del notebook) confermano il contrasto: nello SD *gnädig* (110), *vetter* (36), *jung* (36), *assessor* (29), *baron* (26), *pfarrer* (15) nel Klassizismus *gnädig* (18), *fürst* (12), *kaiser* (12), *könig* (11), *landvogt* (10).

Come vicino di *Herr*, *gnädig* pesa 8,4 per 10.000 parole nello SD contro 1,3 nella Klassizismus. Il dato è coerente con *gnädig* tra le parole SD: lo SD ha un lessico di rapporti sociali gerarchici, con *Herr* come titolo di rango borghese o piccolo-nobiliare, mentre nel Klassizismus *Herr* è più spesso il signore o il sovrano. *Landvogt* viene quasi sicuramente da una sola opera (*Wilhelm Tell*), quindi va letto come esempio, non come tendenza.

5. Posizione dei drammi

Ogni dramma è confrontato con un lessico ricalcolato senza di lui (0 = come la media dei drammi Klassizismus, 1 = come la media dei drammi SD).

Le due classi non si sovrappongono: il Klassizismus ha media 0,0 (deviazione 0,22) e arriva al massimo a 0,51 (*Egmont*).

Lo SD ha media 1,0 (deviazione 0,30) e parte da 0,55 (*Satyros*). Tra i due estremi c'è una distanza di appena 0,05: con una soglia a 0,50 *Egmont* (0,506) finirebbe appena dal lato SD. La scala è calibrata sulle medie delle classi, quindi il margine è quasi nullo.

Drammi più SD: *Die Soldaten* (1,68), *Der Hofmeister* (1,50), *Das leidende Weib* (1,45) e le due opere di Wagner (circa 1,3). Sono drammi domestici e sociali.

Klassizismus più vicini allo SD: *Egmont* (0,51), *Don Carlos* (0,34), *Wallenstein* (0,29), *Wilhelm Tell* (0,13). Sono drammi storici di transizione. Come ipotesi (da verificare), potrebbe contare la presenza di scene popolari.

Klassizismus più lontani dallo SD: *Coriolan* (-0,33), *Der leukadische Fels* (-0,31), *Iphigenie* (-0,17).

SD più vicini alla Klassizismus: *Satyros* (0,55), *Julius von Tarent* (0,74), *Simone Grisaldo* (0,76), *Fiesco* (0,76). *Satyros* ha solo 1.054 parole, quindi la sua posizione è poco affidabile.

La mappa dei campi mostra che il profilo SD è portato soprattutto da Lenz, Klinger e Wagner, mentre *Räuber*, *Fiesco*, *Götz* e *Faust* sono deboli.

Nel Klassizismus i campi 0, 2 e 7 sono più forti in Collin e nei drammi storici di Schiller, e *Egmont* e *Pandora* sono vicini allo zero. Nel grafico per opera, *könig* ha un'opera SD anomala (circa 140) e alcune opere Klassizismus a zero, quindi è fragile come previsto.

6. Verbi tipici di SD e Klassizismus

Un lemma conta come verbo se almeno il 60% delle sue occorrenze è taggato VERB da spaCy: sono 9.612 lemmi su 32.636, di cui 1.158 con almeno 10 occorrenze.

Si applicano gli stessi filtri della sezione 6, con una soglia di Bonferroni calcolata sui soli verbi (16,7 invece di 23,1). Risultano 40 verbi distintivi per classe (il tetto impostato): 22 per lo SD e 23 per il Klassizismus superano tutti e quattro i controlli rapidi (per opera, pesi uguali, autori, log-odds).

Livello	SD	Klassizismus
Affidabili (A nella sezione 3, non toccati dal difetto delle stopword)	<i>lachen, kriegen, schlafen, laufen, lesen, trinken</i>	<i>nahen e schweigen</i> (con riserva, vedi cautele), <i>senden, folgen, ziemen</i>
Solidi ai controlli rapidi (da confermare)	<i>schreiben, küssen, bekommen</i> (B nella sezione 3), <i>beten</i> (in gran parte la forma <i>bitt</i> , vedi cautele), <i>bitten, verzeihen, erzählen, stecken</i>	<i>lösen, sprechen, erscheinen, zeigen, beschützen, ergreifen, bedürfen, retten, ehren, verbergen, vollenden, wirken, erfüllen, empfangen, erheben, bereiten, fassen, schützen</i>
Con riserve (almeno un controllo non superato)	<i>weinen, sitzen, ansehen, ankommen, springen, malen, antworten</i> (non reggono per opera, gli ultimi quattro falliscono anche i log-odds), <i>verlieben, arbeiten, tanzen, essen, fressen, umbringen, ärgern, schmecken, anfangen</i> (non reggono con i log-odds)	<i>scheinen, fordern</i> (non reggono per opera), <i>siegen</i> (supera solo il controllo a pesi uguali: non regge per opera, si inverte in un autore, non regge con i log-odds), <i>vereinen, vollbringen, verehren, beglücken, verkünden, horchen</i> (in gran parte la forma <i>gehört</i> , vedi cautele), <i>fügen, gebieten, verbannen, täuschen, versöhnen, üben, beginnen, bewegen</i> (non reggono con i log-odds)

Livello	SD	Klassizismus
Da non usare finché non è corretto il difetto della sezione 9	<i>sehen, sagen, geben, lassen, gehen, kommen, machen, nehmen, sag</i> (imperativo), <i>wissen</i> (C)	nessuno

Lettura. Nello SD i verbi indicano azioni concrete, corporee e quotidiane (ridere, dormire, correre, bere, baciare, leggere, scrivere) e usano *kriegen* e *bekommen* dove il Klassizismus userebbe verbi più elevati. Nel Klassizismus prevalgono silenzio, protezione, onore e decoro (*schweigen, beschützen, retten, ehren, ziemen, bedürfen*).

Le coppie più “opposizionali” sono *lachen* contro *schweigen* (SD) e *sagen* contro *sprechen* (Klassizismus).

Verbi modali

spaCy considera stopword molte forme dei modali (*kann, soll, will, muss...*), che quindi mancano dall'analisi principale. Per questo la sezione 11b li conta a parte sul testo grezzo (*können, müssen, sollen, wollen, dürfen, mögen* in tutte le forme). Le frequenze sono per 10.000 parole di testo intero:

Modale	SD per 10k	Klassizismus per 10k	G ²
<i>wollen</i>	78,1	43,7	357,2
<i>müssen</i>	36,0	24,5	79,5
<i>können</i>	55,7	42,3	67,1
<i>sollen</i>	48,7	36,9	59,2
<i>dürfen</i>	6,2	9,8	-30,1
<i>mögen</i>	11,4	10,6	0,9

Il risultato è netto: *wollen* è il modale più sbilanciato verso lo SD (volontà, impulso), *müssen, können, sollen* lo seguono, *dürfen* va verso il Klassizismus.

6. Contesto delle parole distintive (sezione 11c)

Per ogni parola il notebook mostra le forme usate, le parole vicine entro tre posizioni (frequenti e specifiche, cioè più frequenti del caso) e tre frasi di esempio per classe. Tutto è salvato in contesti_parole_distintive.xlsx per 160 parole. I casi più chiari, oltre a *herr*:

Parola	Nello SD	Nella Klassizismus
<i>teufel</i>	Imprecazioni: <i>hol</i> (18), <i>holen</i> (10), <i>hölle</i> (9) (289 occ.)	Poche occorrenze (43): <i>hol</i> , <i>tod</i> , <i>arm</i>
<i>kopf</i>	Corpo e violenza: <i>kugel</i> (8), <i>verrückt</i> (7), <i>voll</i> (6), <i>schlinge</i> (3)	Poche occorrenze (42): <i>verlieren</i> , <i>euer</i>
<i>lachen</i>	131 occ.: <i>laut</i> , <i>weinen</i>	15 occ., nessun vicino ricorrente
<i>schweigen</i>	34 occ.: <i>still</i> (6)	146 occ.: <i>lassen</i> (14), <i>stimme</i> (6), <i>busen</i> (5), <i>tief</i> (5)
<i>nahen</i>	45 occ. nella scheda, quasi solo l'aggettivo <i>nahe</i>	153 occ. (<i>naht</i> 56, <i>nahn</i> 32): <i>tod</i> , <i>freund</i>
<i>senden</i>	10 occ.	95 occ.: <i>gott</i> (7), <i>könig</i> (4), <i>engel</i> (3)
<i>sehen, sagen</i>	Vicini simili nelle due classi (<i>auge</i> , <i>lassen</i>): cambia la frequenza, non il contesto	

Attenzione: I vicini con 3-6 occorrenze sono rumorosi. Possono venire da una sola opera (*landvogt* da *Tell*, *schildlein* da *Wallenstein*), da refusi o forme elise (*hieh*, *ichs*, *möchen*, *aug*) o da possessivi sfuggiti al filtro (*dein*, *eurer*). Vanno letti solo i vicini con almeno 5-6 occorrenze e più opere.

I pronomi non compaiono tra i vicini, perché sono scartati dal filtro. Per *sagen*, *sehen*, *geben*, *lassen* la differenza tra le classi è concentrata in forme che coincidono con la terza persona plurale (*sagen* circa 38 contro 15 per 10.000, *sage* e *sagst* sono pari).

Lassen compare tra i vicini di quasi tutto (*schweigen lassen*, *sehen lassen*): è un verbo ausiliare, i suoi vicini dicono poco.

7. Problemi del notebook

Statistica

Soglia di Bonferroni: è calcolata su 32.636 parole, ma se ne testano di fatto molte meno. È prudente, ma resta una scelta. Le parole con almeno 10 occorrenze sono 3.661: con quel numero la soglia sarebbe 18,9 invece di 23,1 e le parole distintive passerebbero da 369 (175 SD e 194 Klassizismus) a 487 (235 e 252).

Verdetti A/B/C: «A» richiede 11 controlli insieme, e alcuni sono correlati. Una parola B non è sbagliata: *papa* e *mama* falliscono per i log-odds solo perché sono rare.

Corpus

Lenz e Klinger hanno 10 delle 21 opere SD (cinque ciascuno).

Goethe e Schiller sono in entrambe le classi (9 opere ciascuno).

Verso e prosa non entrano nel notebook, ma possono essere un confondente.

8. Prossimi passi

1. ulteriori analisi

Ex. Studio del registro come confronto “Kopf” (testa) e “Huapt” (testa, più aulico), il primo più presente in SD e il secondo nel Klassizismus.

2. Confronto con altre opere

Lo script ha già gli ingredienti: l'asse lessicale 0 = Klassizismus, 1 = SD, con la logica leave-one-out.

Estenderlo significa proiettare drammi nuovi sull'asse, usando un lessico «congelato» costruito sulle 38 opere attuali.

I passi:

1. Salvare i pesi ($\log_2$ ratio delle parole con G^2 sopra Bonferroni) in un CSV, insieme ai valori `m_k` e `m_sd` per la riscaturatura.
2. Prendere altre opere da GerDraCor (il file `gerdracor_opere.xlsx` ha già i metadati) e lemmatizzarle con lo stesso modello spaCy (`de_core_news_sm`).
3. Calcolare per ciascuna Xrel @ pesi e riscaturare come ora.

Cosa si può chiedere all'asse:

Opere di controllo con posizione attesa: autori non presenti nel corpus, per esempio Lessing (precedente), Kleist e Büchner (dopo o fuori dai due gruppi). Lenz e Wagner sono già nel corpus (5 e 2 opere) e non servono come controllo fuori campione.

Il rischio principale sono i confondenti. L'asse potrebbe catturare in parte verso vs prosa (le apocopi sono già un segnale), genere (commedia/tragedia), anno di composizione o lunghezza dell'opera...però da verificare

3. Un sito

I risultati sono già tabelle (parole distintive, posizione per opera, controlli), quindi si possono esportare in JSON/CSV e servire come sito statico (GitHub Pages, ad esempio). Cosa potrebbe contenere:

grafico interattivo dell'asse con ogni dramma cliccabile (Plotly o D3), ricerca di una parola, con la sua frequenza per classe e per opera e le schede di contesto, tabelle delle parole distintive e dei verbi, filtrabili, una pagina di metodo.